



Introdução a Redes Neurais


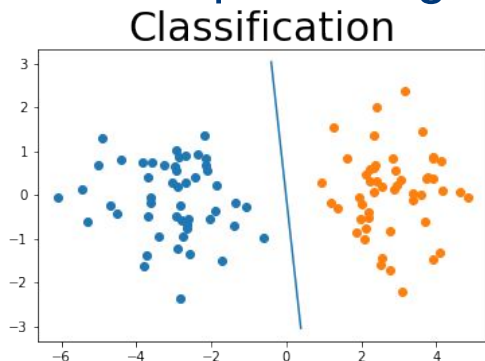
Arquiteturas MLP e CNN

Joris GUERIN

*Concurso para Professor Adjunto em Aprendizado de Máquina
Departamento de Informática e Matemática Aplicada (DIMAP)
Universidade Federal do Rio Grande do Norte (UFRN)*

Pré-requisitos

- Problemas de aprendizagem: Classificação / Regressão



- Funções de perda

- Classificação: **Cross-Entropy**

$$L_{CE}(F, X, y) = -\frac{1}{N} \sum_{i=1}^N y_i \log(F(x_i))$$

- Regression: **Mean Squared Error**

$$L_{MSE}(F, X, y) = -\frac{1}{N} \sum_{i=1}^N ||y_i - F(x_i)||^2$$


Pré-requisitos

- Modelos lineares

$$F(x) = \omega^T x + b$$

- Treinamento / otimização

- Resolução exata
- Métodos iterativos: Gradiente Descendente





- Pré-processamento de dados: padronização
- Avaliação de classificadores: acurácia

Multi-Layer Perceptron

Uma primeira arquitetura de rede neural artificial

Motivações

- Modelização de funções não-lineares

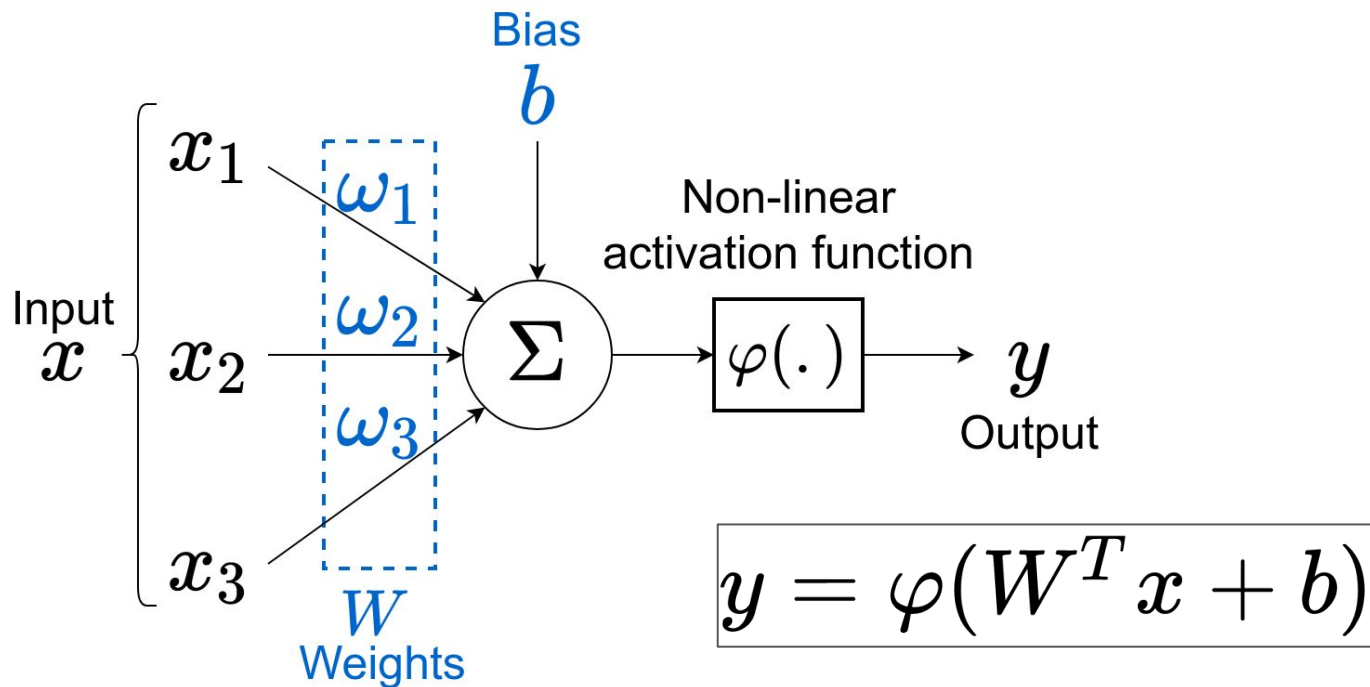


- Porquê MLP entre outros modelos não-lineares

- **Teoria:** Teorema da aproximação universal
- **Prática:** Permite resolver problemas muito complexos
- **Implementação:** Combinação de funções simples
 - → Fácil de usar o gradiente descendente
 - → Fácil de otimizar o treinamento rápido com GPU

Arquitetura MLP

- Modelo de neurônio simples




Arquitetura MLP

- Funções de ativação comuns

Sigmoid

$$\varphi(x) = \frac{e^x}{1+e^x} = \frac{1}{1+e^{-x}}$$


Sigmoid



Tanh

$$\varphi(x) = 1 - \frac{2}{1+e^{2x}}$$


Tanh



ReLU


$$\varphi(x) = \max(0, x)$$

Rectified Linear Unit (ReLU)



Arquitetura MLP

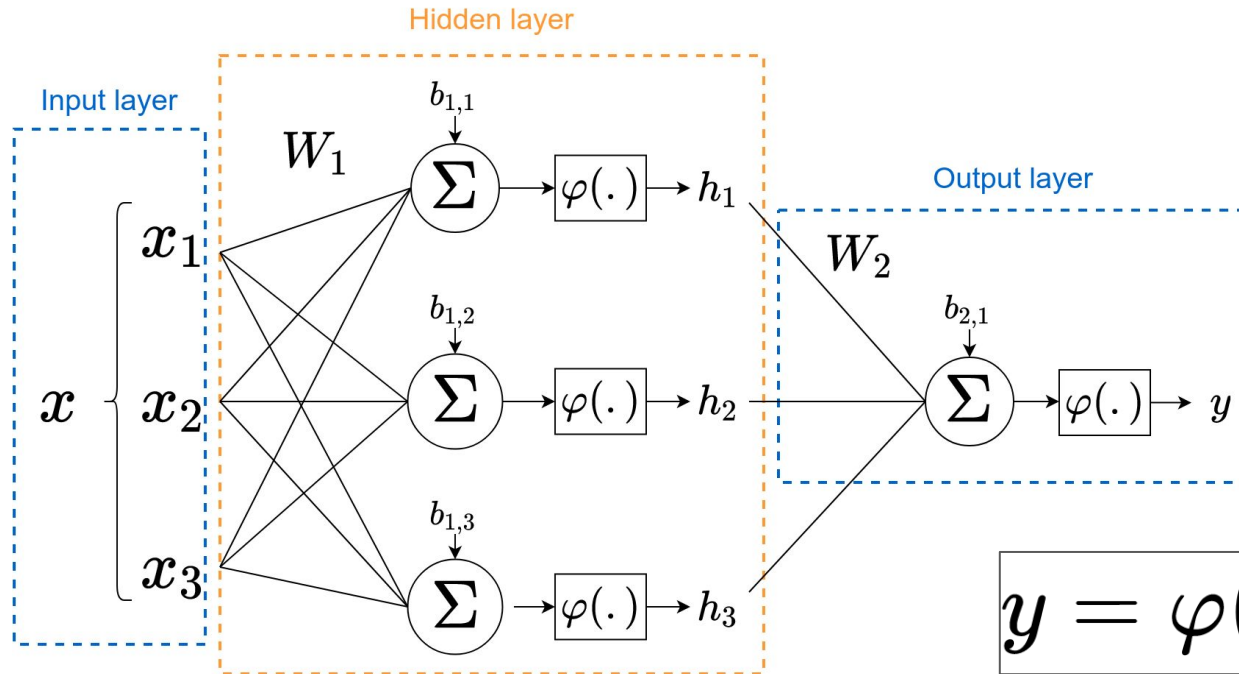
- Modelo de camada de neurônios (*layer*)



$$\forall i \in \{1, 2\},$$
$$y_i = \varphi(W_i^T x + b_i)$$

Arquitetura MLP

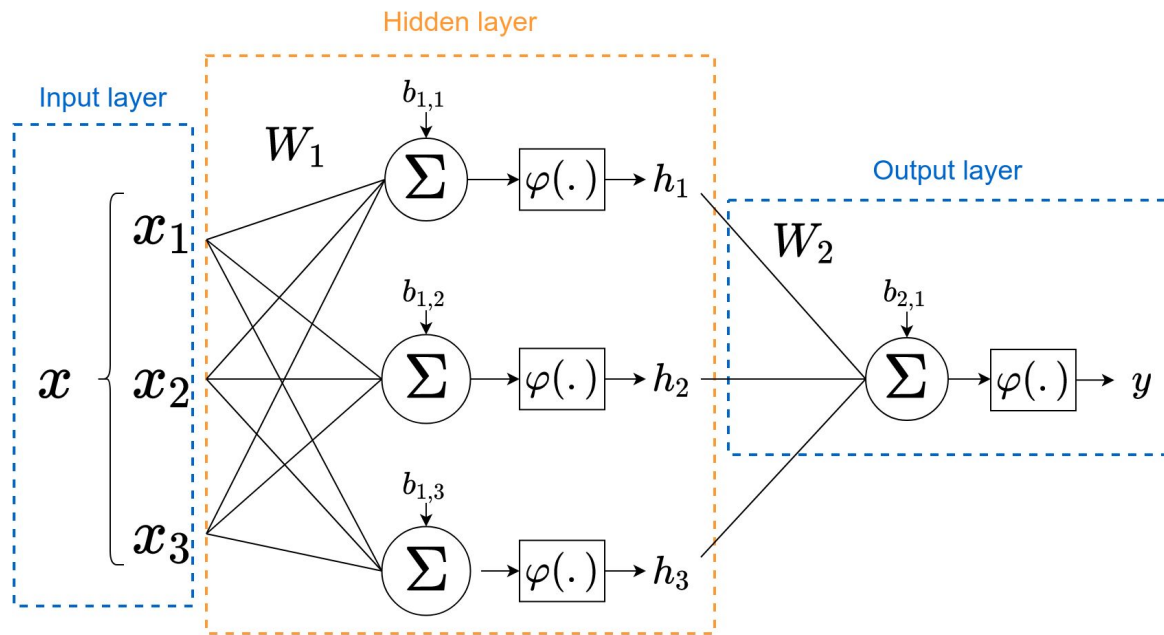
- Modelo de Multi-Layer Perceptron (MLP)



Restrições sobre a arquitetura

- O tamanho da camada de entrada é a dimensão dos dados
- O tamanho da camada de saída depende dos rótulos
 - Classificação: número de neurônios de saída = número de categorias
 - Regressão: número de neurônios de saída = número de valores a estimar (geralmente 1)
- A função de ativação da camada de saída depende da faixa de valores
 - Exemplo: regressão de variáveis resposta num intervalo fixo: Sigmoid
- O número de parâmetros não deve ser muito maior do que o número de amostras → Regra empírica

Calcular número de parâmetros



$$\begin{aligned} N_{i,j}^{\text{params}} &= d_i^{\text{in}} + 1 \\ N_i^{\text{params}} &= \sum_j N_{i,j}^{\text{params}} \\ &= N_i^{\text{neurons}} \times (d_i^{\text{in}} + 1) \\ N^{\text{params}} &= \sum_i N_i^{\text{params}} \end{aligned}$$

$$[3 \times (3 + 1)] + [1 \times (3 + 1)] = 16$$

Regra empírica para construção de arquitetura MLP

- Começar com 2 hidden layers
- Em cada camada: usar potências de 2 para números de neurônios (2, 4, 8, 16, 32, etc.)
 - Primeira camada ~ a metade do número de features
 - Camadas seguintes: metade da camada anterior
- Este esquema dá uma boa arquitetura para começar o processo de treinamento, mas geralmente o desenvolvimento de uma rede neural é um processo iterativo onde se precisa testar muitas configurações.

Exemplo

- Treinamento de um MLP para o dataset **Wine**

13 FEATURES <i>Propriedades químicas do vinho</i>
Alcohol
Malic acid
Ash
Alkalinity of ash
Magnesium
Total phenols
Etc.



178 AMOSTRAS

*Diferentes produtores da
mesma região na Itália*

3 CATEGORIAS

*Diferentes espécies de uva
usadas*

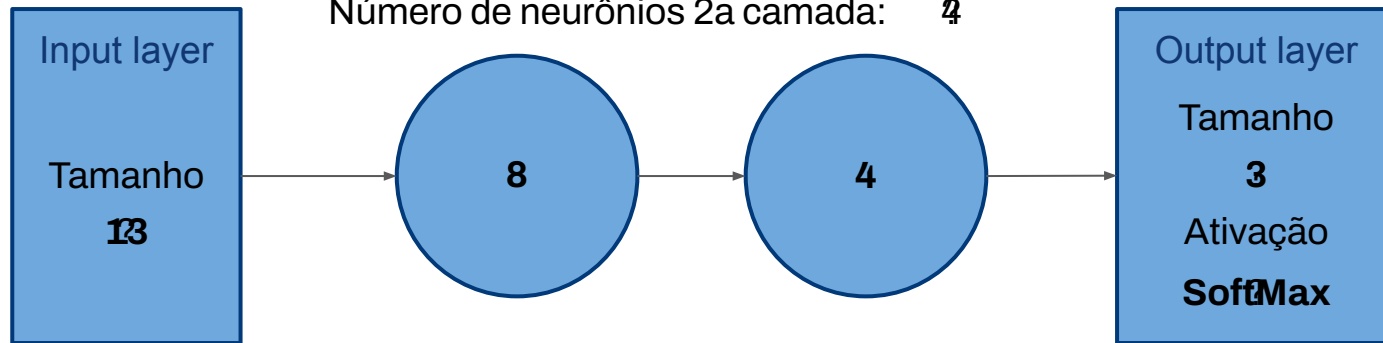
Exemplo

178 Amostras
13 Features
3 Categorias

Número de parâmetros escondidos: $8 \times (13 + 1) + 2 \times (8 + 1)$

Número de neurônios 1a camada: 8

Número de neurônios 2a camada: 4



- Começar com 2 hidden layers
- Em cada camada: usar potências de 2 para números de neurônios (2, 4, 8, 16, 32, etc.)
- Primeira camada ~ a metade do número de features
- Camadas seguintes: metade da camada anterior

Exemplo de implementação



```
from sklearn.datasets import load_wine
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.neural_network import MLPClassifier
from sklearn.metrics import accuracy_score

# Load data
data = load_wine()
X = data.data
y = data.target

# Split into train and test set
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3)


# Preprocess data
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

# Build MLP
mlp = MLPClassifier(hidden_layer_sizes=[8, 4], max_iter=10000)
# Train MLP
mlp.fit(X_train, y_train)
# Predict on test set
y_pred = mlp.predict(X_test)

# Compute accuracy score
print("Accuracy MLP: ", accuracy_score(y_pred, y_test))
```

Accuracy MLP: 1.0

Descrição básica do processo de treinamento



Conclusão intermediária

- Apresentamos a arquitetura MLP e mostramos como pode ser desenvolvida
- Muitos elementos importantes sobre treinamento de redes neurais não foram discutidos ainda (próximas aulas)

Inicialização

Otimização

Regularização

Avaliação

Implementação eficiente


Implantação industrial

Convolutional Neural Network


Rede neural artificial para processamento de imagens

Motivações: aprendizado para análise de imagens

- Classificação de imagens



- Detecção de objetos



Motivações: aprendizado para análise de imagens

- Super resolution / Image denoising



- Pose recognition



Motivações: aprendizado para análise de imagens


- Geração de imagens / Geração de arte



Motivações: problemas com MLP para imagens

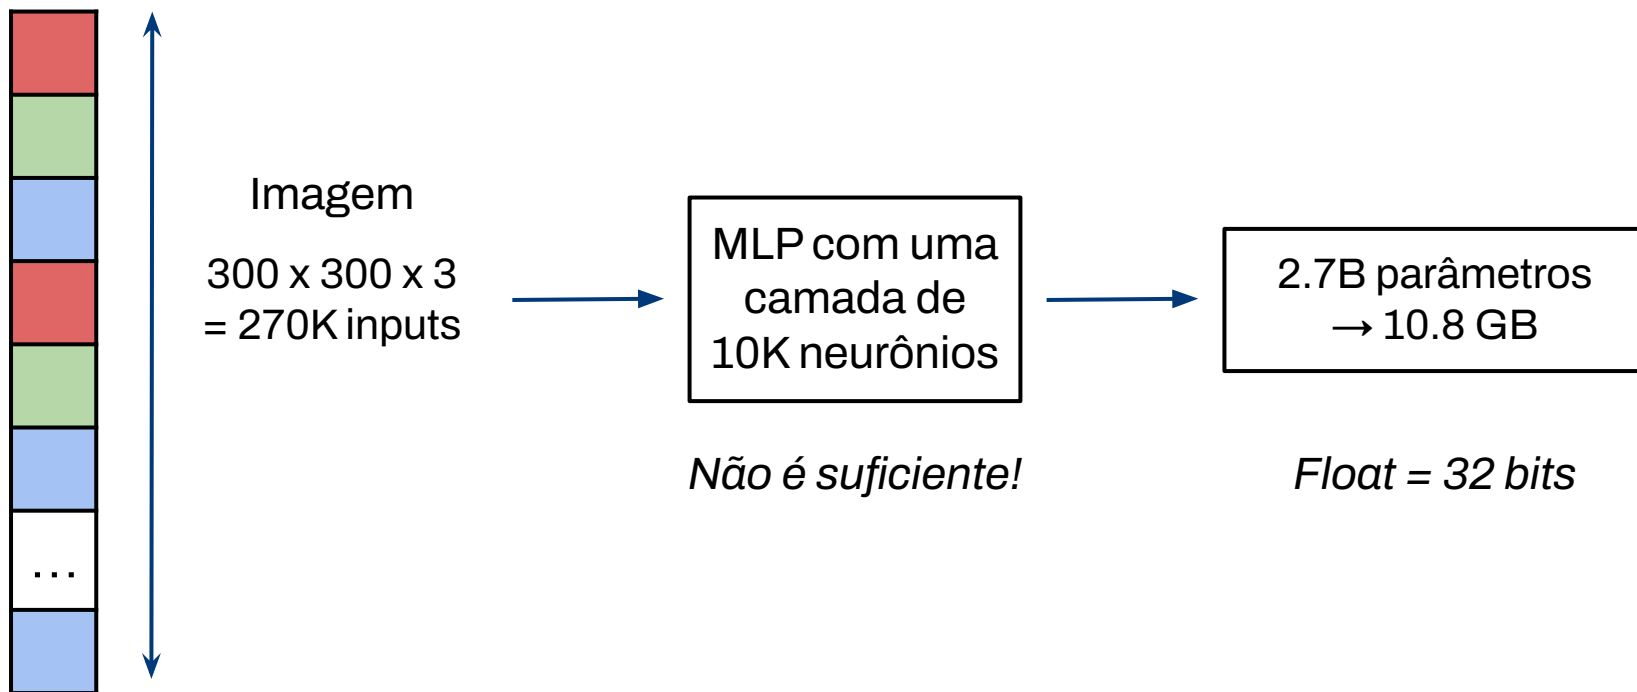
Classificar imagens usando MLP

Uma imagem pode ser representada por um tensor (Matrice 3D) de dimensão $W \times H \times 3$




Motivações: problemas com MLP para imagens

- Explosão do número de parâmetros necessários



Motivações: problemas com MLP para imagens



- Número de parâmetros necessários
- **Invariância à translação**



Motivações: problemas com MLP para imagens

- Número de parâmetros
- Invariância à translação
- **Invariância à escala**
- **Invariância à rotação**

Convolutional Neural Networks
(CNN)



Arquitetura CNN

Filtro de convolução e produto escalar de matrizes

Filtro

Imagem

$$\begin{array}{|c|c|c|} \hline \omega_{11} & \omega_{12} & \omega_{13} \\ \hline \omega_{21} & \omega_{22} & \omega_{23} \\ \hline \omega_{31} & \omega_{32} & \omega_{33} \\ \hline \end{array} \bullet \begin{array}{|c|c|c|} \hline x_{11} & x_{12} & x_{13} \\ \hline x_{21} & x_{22} & x_{23} \\ \hline x_{31} & x_{32} & x_{33} \\ \hline \end{array} = \sum_i \sum_j w_{ij} x_{ij}$$

H


W

Extensão 3D $\longrightarrow \sum_i \sum_j \sum_k w_{ijk} x_{ijk}$

Arquitetura CNN

Exemplo: filtros de convolução para detectar orelha de gato

Imagem em escala de cinza




representação numérica

3	0	0	3	0
0	0	10	0	3
0	10	3	10	0
10	3	3	3	10
3	3	3	3	3

Arquitetura CNN

Etapa 1: detecção de bordas inclinadas

Padrão procurado



Filtro de convolução




-1	-1	1
-1	1	-1
1	-1	-1

=

Valor alto quando padrão,
Valor baixo senão

30



-1	-1	1
-1	1	-1
1	-1	-1


=

~~30~~
-30


Arquitetura CNN

Etapa 1: detecção de bordas inclinadas

$$\varphi(x) = \max(0, x)$$



Padrão procurado



0	0	10
0	10	0
10	0	0

Filtro de convolução



-1	-1	1
-1	1	-1
1	-1	-1


= 30



ReLU



30



9	9	10
9	10	9
10	9	9



-1	-1	1
-1	1	-1
1	-1	-1

= -24



ReLU




0

Arquitetura CNN

Aplicar o filtro à imagem toda

Imagem em escala de cinza



Representação numérica

3	0	0	3	0
0	0	10	0	3
0	10	3	10	0
10	3	3	3	10
3	3	3	3	3

?

Filtro de convolução

-1	-1	1
-1	1	-1
1	-1	-1


Resultado da convolução

		10		

Arquitetura CNN

Aplicar o filtro à imagem toda

Imagem em escala de cinza



Representação numérica

0	0	0	0	0	0	0
0	3	0	0	3	0	0
0	0	0	10	0	3	0
0	0	10	3	10	0	0
0	10	3	3	3	10	0
0	3	3	3	3	3	0
0	0	0	0	0	0	0

Zero-padding

Filtro de convolução

-1	-1	1
-1	1	-1
1	-1	-1


Resultado da convolução

3				
		10		

Arquitetura CNN

Aplicar o filtro à imagem toda

Imagem em escala de cinza



Representação numérica

0	0	0	0	0	0	0
0	3	0	0	3	0	0
0	0	0	10	0	3	0
0	0	10	3	10	0	0
0	10	3	3	3	10	0
0	3	3	3	3	3	0
0	0	0	0	0	0	0

Filtro de convolução

-1	-1	1
-1	1	-1
1	-1	-1

Resultado da convolução

3	-13	-13	10	-6
-13	-26	10	-23	10
-23	21	-30	-10	-20
11	-20	-9	-26	-3
-7	-13	-6	1	-13

Arquitetura CNN

Aplicar a não-linearidade

Resultado da convolução

3	-13	-13	10	-6
-13	-26	10	-23	10
-23	21	-30	-10	-20
11	-20	-9	-26	-3
-7	-13	-6	1	-13



ReLU




Saída da camada de convolução

3	0	0	10	0
0	0	10	0	10
0	21	0	0	0
11	0	0	0	0
0	0	0	1	0

Arquitetura CNN

Operação de Max-pooling



Arquitetura CNN

Operação de Max-pooling

Saída da camada de convolução

3	0	0	10	0
0	0	10	0	10
0	21	0	0	0
11	0	0	0	0
0	0	0	1	0



Max
pooling
2x2




Saída da camada de max pooling

3	10	10
21	0	0
0	1	0

Arquitetura CNN

Porquê Max pooling?




- **Número de parâmetros**
(Tamanho da imagem dividido por 4)
- **Invariância à translação**
(Ativação independente da posição exata)
- Invariância à escala
- Invariância à rotação

Arquitetura CNN

Detecção de orelha de gato

Imagem



Representação numérica

3	0	0	3	0
0	0	10	0	3
0	10	3	10	0
10	3	3	3	10
3	3	3	3	3

Filtro 1

-1	-1	1
-1	1	-1
1	-1	-1

Filtro 2

1	-1	-1
-1	1	-1
-1	-1	1

Nova imagem

Canal 1

3	10	10
21	0	0
0	1	0


Canal 2

7	10	0
0	18	11
1	0	0

Exercício: Repete o processo de convolução + pooling com o filtro 2

Arquitetura CNN

Filtro de convolução da segunda camada



Filtro de convolução 3D

Canal 1

-1	-1	-1
-1	1	-1
-1	-1	-1

Canal 2

-1	-1	-1
-1	-1	1
-1	-1	-1

Resultado da convolução

-43	-70	-39
7	-70	-60
-41	-50	-30

Exercício: Calcular a convolução 2D

Arquitetura CNN

Filtro de convolução da segunda camada

Imagem

Gray	White	White	Gray	White
White	White	Black	White	Gray
White	Black	Gray	Black	White
Black	Gray	Gray	Gray	Black
Gray	Gray	Gray	Gray	Gray

Resultado da convolução


-43	-70	-39
7	-70	-60
-41	-50	-30

ReLU

0	0	0
7	0	0
0	0	0

Arquitetura CNN

Camada de classificação



Conclusão: Tem uma orelha de gato na imagem

Arquitetura CNN

Outro mecanismo de redução de tamanho: **Stride**

Stride = 1

3	0	0	3	0
0	0	10	0	3
0	10	3	10	0
10	3	3	3	10
3	3	3	3	3

Stride = 2

3	0	0	3	0
0	0	10	0	3
0	10	3	10	0
10	3	3	3	10
3	3	3	3	3


Stride = 3

3	0	0	3	0
0	0	10	0	3
0	10	3	10	0
10	3	3	3	10
3	3	3	3	3

Arquitetura CNN

CNN na prática

Filtros de convolução parametrizados e aprendidos



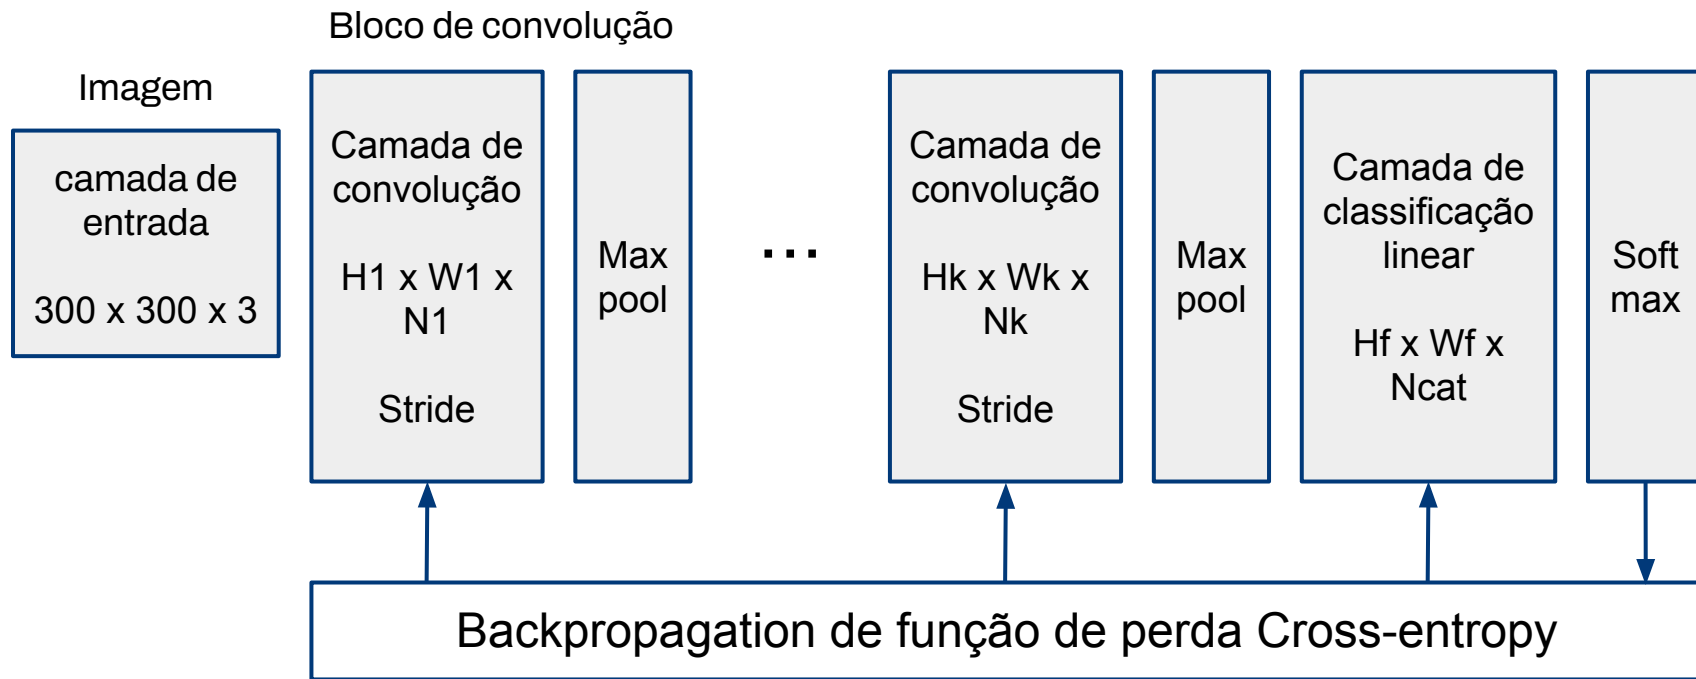
Número de parâmetros de 1 filtro 3x3
aplicado à uma imagem RGB?

$$3 \times 3 \times 3 = 27$$


Aplicado à profundidade inteira da
imagem de entrada

Arquitetura CNN

Definir uma arquitetura CNN




Número de parâmetros: MLP vs CNN

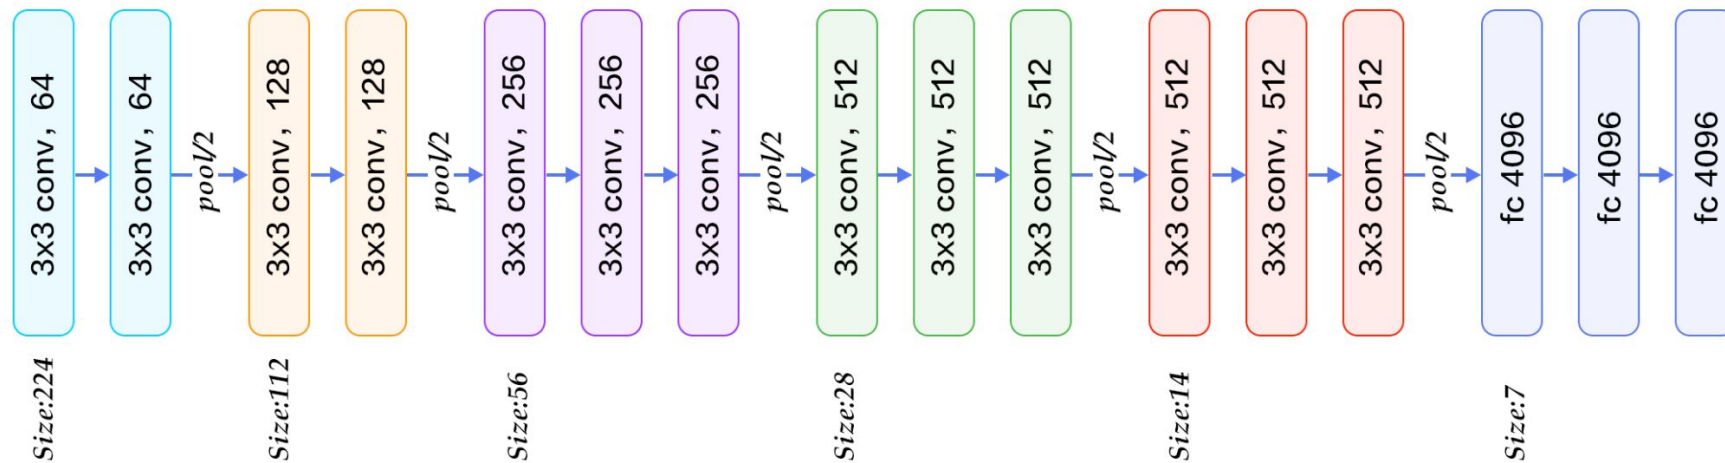


Competição ImageNet (ILSVRC 2012)

Classificar imagens entre 1000 categorias
1.2M imagens de treinamento | 150K imagens de teste




Arquitetura VGG 16



Model	Size (MB)	Top-1 Accuracy	Top-5 Accuracy	Parameters	Depth	Time (ms) per inference step (CPU)	Time (ms) per inference step (GPU)
Xception	88	0.790	0.945	22,910,480	126	109.42	8.06
VGG16	528	0.713	0.901	138,357,544	23	69.50	4.16
VGG19	549	0.713	0.900	143,667,240	26	84.75	4.38


Reflexões: Adaptação da arquitetura CNN para vídeos

Imagens →



Convolução 2D

Vídeos →



Convolução 3D

Conclusão

- Apresentamos a arquitetura MLP e mostramos como pode ser desenvolvida → Dados tabulares
- Apresentamos a arquitetura CNN e mostramos como pode ser desenvolvida → Imagens
- Muitos elementos importantes sobre treinamento de redes neurais não foram discutidos ainda (próximas aulas)

Inicialização

Otimização

Regularização

Avaliação

Implementação eficiente

Implantação industrial

Antes da próxima aula

- Apresentamos a arquitetura MLP e mostramos como pode ser desenvolvida → Dados tabulares
- Apresentamos a arquitetura CNN e mostramos como pode ser desenvolvida → Imagens
- Muitos elementos importantes sobre treinamento de redes neurais não foram discutidos ainda (próximas aulas)

Inicialização

Otimização

Regularização

Avaliação

Implementação eficiente

Implantação industrial

Título principal

Título secundário